Ciência de Dados | Kaggle Dataset

PREVISÃO DE PARADAS EM MÁQUINAS INDUSTRIAIS

Monica N. De Resende

#KaggleDataset

Introdução

Na fabricação de componentes metálicos de alta precisão — usados nos setores aeroespacial, automotivo e médico — há 3 máquinas responsáveis por produzir peças de diferentes tamanhos.

Reduzir o tempo de inatividade dessas máquinas é essencial para cumprir prazos de produção.

Com base em dados operacionais coletados ao longo de 7 meses, o objetivo **é adotar uma abordagem baseada em dados para prever falhas e permitir o planejamento de manutenções preventivas**, substituindo o modelo reativo atual.

Esta análise representa o primeiro passo para aumentar a confiabilidade das máquinas e otimizar estratégias e cronogramas de manutenção.

Possível redução de custos, ampliação da produção e ganhos em escala

Cumprir Prazos

Otimizar estratégias & cronograma de manutenção

Reduzir tempo de inatividade

Manutenção Preditiva

Sumário da Análise

- Análise Exploratória
- Modelagem & Predição
- Interpretabilidade do Modelo
- Simulação interativa para avaliação do ROI
- Conclusão & Próximos Passos
- Autoria & Trabalho Completo no Kaggle

#Kaggle Dataset

Análise Exploratória

Pré-processamento: as principais transformações de dados foram a conversão de tipos de dados e mapeamento dos valores da variável-alvo.

Os Dados

Observações representam uma leitura operacional:

- dados operacionais contínuos coletados em uma das **máquinas**, de uma das **linhas de produção**, em uma **data**, e o respectivo **status operacional**.

221 Dias (24/11/2021 até 03/07/2022)

2.5K Leituras operacionais

Variáveis Chave

Dados operacionais continuous

- Corte
- Torque
- Voltagem
- Vibração da Ferramenta
- Vibração do Spindle
- Temperatura do Óleo Hidráulico
- Temperatura do Fluido de Refrigeração
- Temperatura do Rolamento do Spindle
- Pressão do Fluido de Refrigeração
- Pressão do Sistema de Ar
- Pressão Hidráulica
- Velocidade do Spindle

Qualidade dos dados

O dataset apresenta boa qualidade geral porém algumas limitações podem indicar falhas na coleta, paradas planejadas, interrupção de coleta ou não monitoradas, e precisam ser consideradas na interpretação dos resultados

5.72% Baixo índice de dados ausentes

Sem duplicatas e apenas 143 valores faltantes, menos que 1% por variável). **Imputação pela mediana**, considerando máquina e status operacional.

Desbalanceamento de Leituras & Lacunas no Tempo

O nº de leituras está desigualmente distribuído entre as máquinas, indicando desbalanceamento na coleta. Há gaps temporais, com ausência total de leituras em alguns trechos do tempo analisado — especialmente no início e no final do dataset.

Anomalias de Medição

Foram identificadas possíveis falhas ou inconsistências nas medições, incluindo: valores negativos, extremamente altos e leituras próximas de zero.

Falta de detalhes sobre a coleta

Não foram fornecidos detalhes sobre o processo de coleta de dados — como estratégias ou metodologias adotadas.

Fabricação de componentes metálicos de alta precisão

O sistema industrial analisado é composto por 3 linhas de montagem, e cada linha possui 1 máquina dedicada.

Distribuição de Leituras diárias

O nº de leituras por dia flutuou ao longo do tempo, atingindo um pico de mais de 12 leituras diárias (na média móvel de 7 dias).

Em geral, a média é de 4 a 5 leituras diárias em cada máquina.

MÉDIA MÓVEL DE 7 DIAS DAS LEITURAS

MAKINO-L1-UNIT1-2013

Linha de Montagem Shopfloor-L1

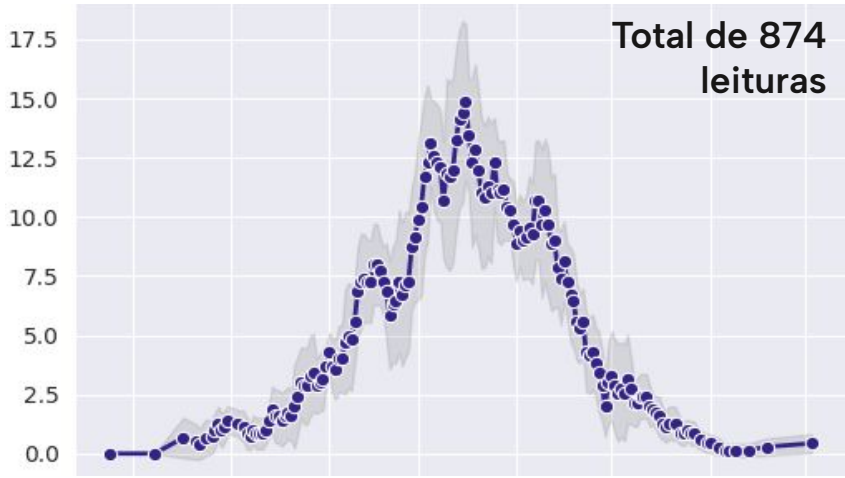

MAKINO-L2-UNIT1-2015

Linha de Montagem Shopfloor-L2

MAKINO-L3-UNIT1-2015

Linha de Montagem Shopfloor-L3

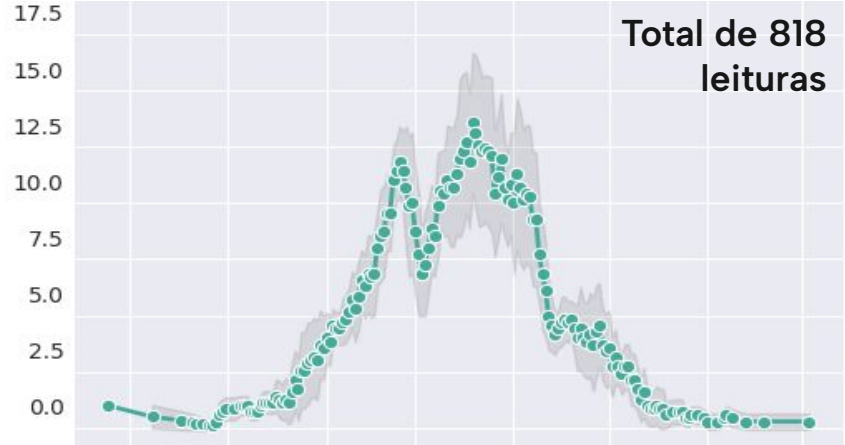

Análise da Taxa de Downtime

Os 2 estados operacionais são
OPERACIONAL ou **NÃO OPERACIONAL (downtime)**

Taxa de Downtime

54%

MAKINO-L1-UNIT1-2013
22 ocorrências de parada
total (100%)

46%

MAKINO-L2-UNIT1-2015
17 ocorrências de parada
total (100%)

51%

MAKINO-L3-UNIT1-2015
19 ocorrências de parada
total (100%)

Média Móvel de 7 Dias (GERAL)

DISTRIBUIÇÃO DE TAXAS DE DOWNTIME
(MÉDIA MÓVEL DE 7 DIAS)

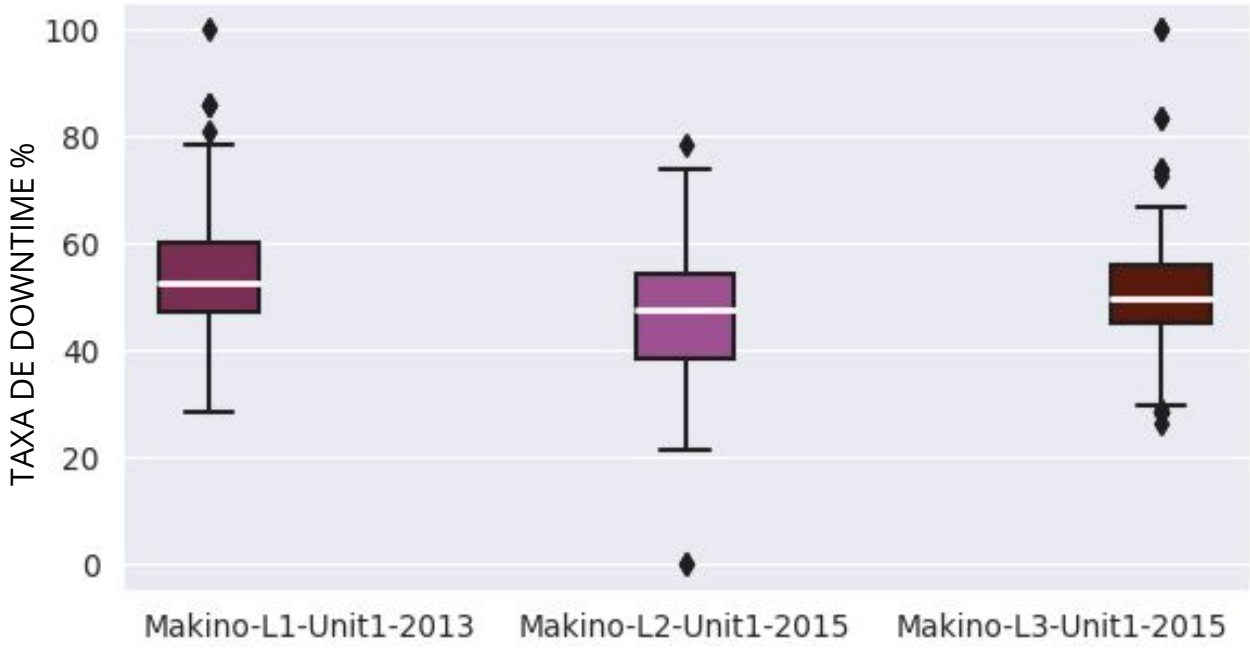

Evolução Temporal

EVOLUÇÃO DA TAXA DE DOWNTIME (MÉDIA MÓVEL – 7 DIAS)

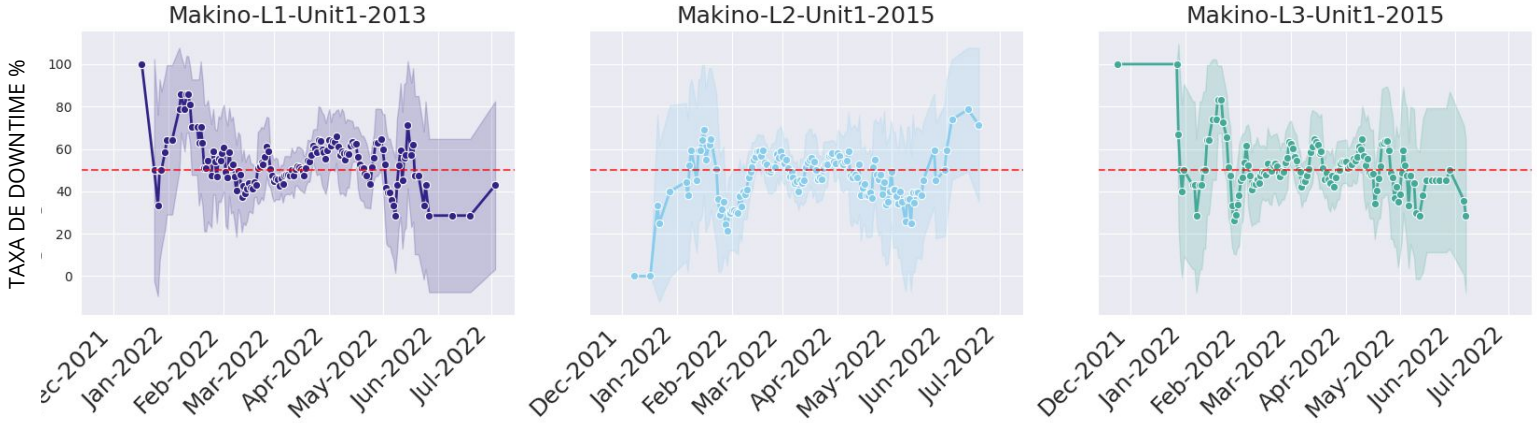

Padrões Semanais de Downtime

- Paradas foram registradas em quase todas as semanas (exceto 2 semanas).
- Sábados apresentaram pelo menos uma parada durante todo o período.
- Quartas-feiras tiveram a menor frequência de downtime, com cerca de 84% dos dias apresentando alguma ocorrência.

100% Downtime

Em 48 dias a taxa de downtime de alguma das máquinas foi de 100%, no entanto, as ocorrências de parada total restringiram-se a apenas 1 ou, no máximo, 2 linhas de montagem.

OCORRÊNCIAS DE 100% DOWNTIME

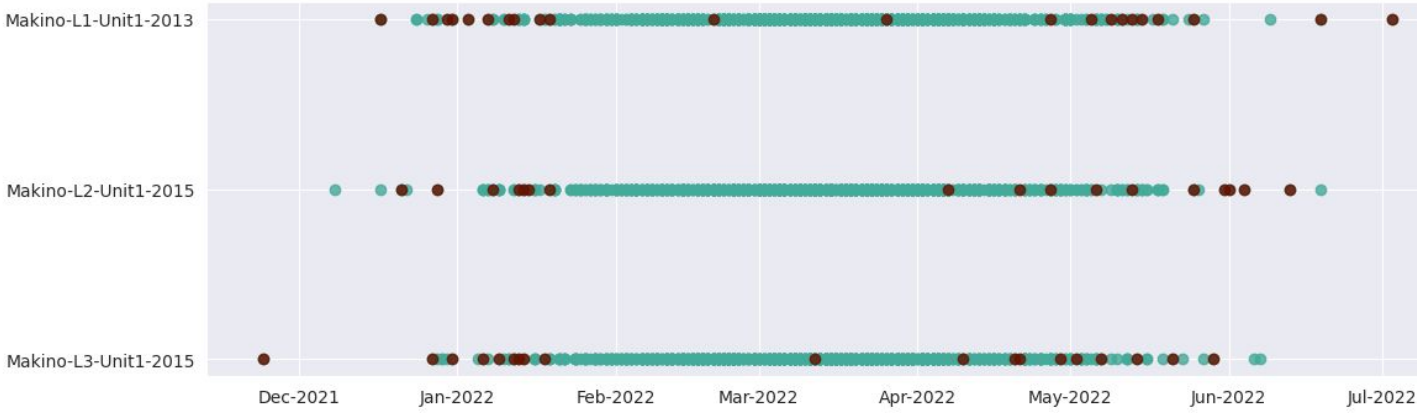

Variáveis Contínuas

Máquinas & Dados Operacionais

Os intervalos de confiança para cada variável, agrupados por máquina e status operacional, indicam que, de forma geral, as 3 máquinas **operam de maneira semelhante.**

- Consistência Operacional entre Máquinas
- Análise geral segmentada apenas pelo status operacional é suficiente

Relação entre Variáveis Operacionais e Downtime

As variáveis estatisticamente significativas na distinção entre estados de operação, são:

- Pressão Hidráulica — **Alto efeito**
- Torque e Ação de Corte — **Efeito médio**
- Velocidade do Spindle e Temperatura do Fluido de Refrigeração — **Efeitos de pequeno a moderado**

Padrões Significativos

- **Reduções** nos valores de pressão hidráulica e torque estão associadas com downtime
- Valores **mais altos** de força de corte estão relacionados a mais paradas.
- Rotações **mais altas** tendem a estar associadas a um aumento no downtime, embora o efeito seja mais sutil.
- Temp. do Fluido de Refrigeração, sugere que valores **elevados** podem contribuir ocasionalmente para paradas.

VARIÁVEIS DE MAIOR RELEVÂNCIA PARA PREDIÇÃO DE DOWNTIME

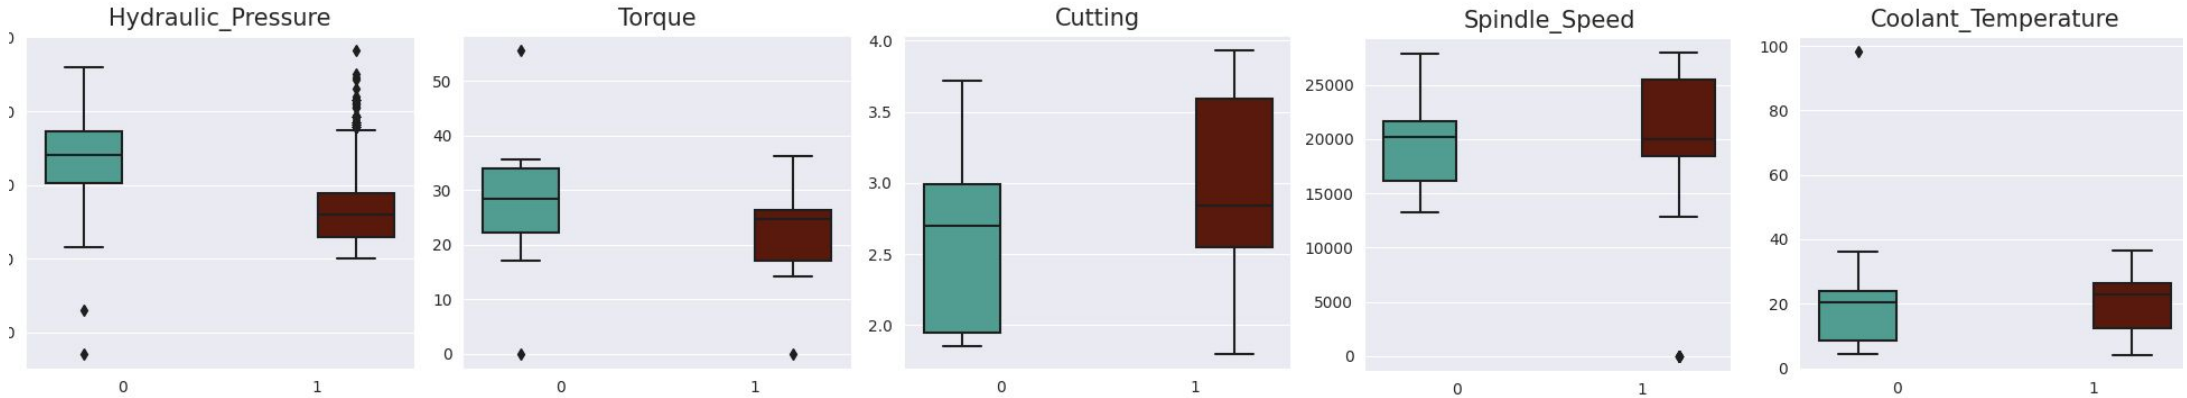

#Aprendizado de Máquina

Previsão de Falhas nas Máquinas

O objetivo é **prever ocorrências de downtime** com base em padrões históricos das leituras dos sensores, tanto durante o funcionamento normal quanto em momentos de falha.

>> Essa previsão permite adotar **medidas proativas** para **minimizar interrupções** na produção.

Trata-se, portanto, de um problema de classificação binária, em que o modelo deve ser otimizado para:

- **REDUZIR FALSOS POSITIVOS**
  (evitar paradas desnecessárias)
- **REDUZIR FALSOS NEGATIVOS**
  (garantir que falhas reais sejam detectadas)

O Processo:

Métricas	**F1-Score** **Área de Precisão-Recall sob a Curva** As quais equilibram precisão e sensibilidade.
Treinamento e Validação	O conj. de dados apresenta distribuição binária aproximadamente balanceada. Foi dividido em 70% treino e 30% teste. O treinamento foi realizado com validação cruzada de 5-FOLD.
Modelos Avaliados	**Regressão Logística** (modelo de referência / baseline) **XGBoost Classifier** (modelo baseado em árvores)

- ✓ PREVISÃO DE DOWNTIME
- ✓ MANUTENÇÃO PROATIVA
- ✓ AUMENTO DA DISPONIBILIDADE

#Previsão de Downtime

Desempenho dos Modelos

XGBoost superou o modelo de Regressão Logística

XGBoost

- Acurácia 99,9%
- PR-AUC = 1,00
- Apenas 1 falso negativo (0,3%)
- F1-score de 99% por classe

Regressão Logística

- Acurácia 81,9%
- PR-AUC = 0,898
- 17,4% de falsos positivos
- 18,8% de falsos negativos
- F1-score até 82% por classe

MATRIZ DE CONFUSÃO DOS MODELOS

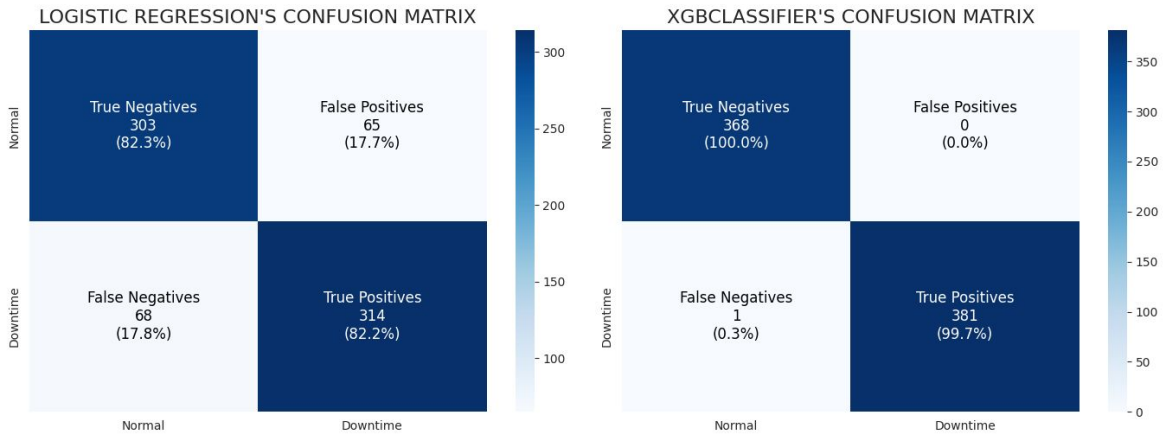

PRECISÃO E SENSIBILIDADE DURANTE TREINAMENTO E TESTE

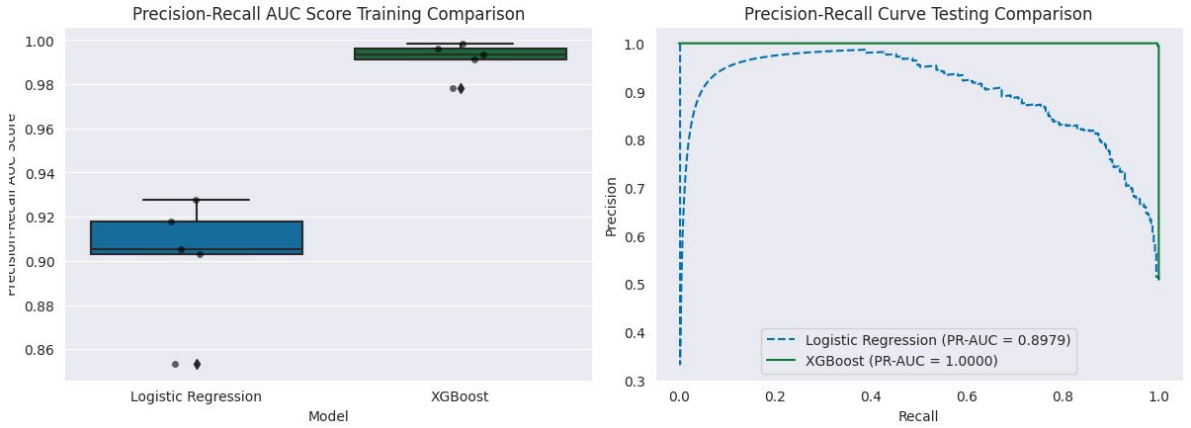

Importância das Variáveis no Modelo XGBoost

Pressão Hidráulica, Torque e Força de Corte se destacaram de forma recorrente, reforçando seu papel crítico na previsão de downtime.

Variáveis mais relevantes

Os resultados obtidos pelas abordagens de importância do XGBoost e dos valores SHAP foram coerentes com as correlações e testes estatísticos realizados anteriormente.

Ambas as técnicas reforçam a relevância das principais variáveis, com pequenas variações na ordem e no destaque das demais, evidenciando consistência entre as análises.

IMPACTO REAL NAS PREVISÕES (SHAP VALUES)

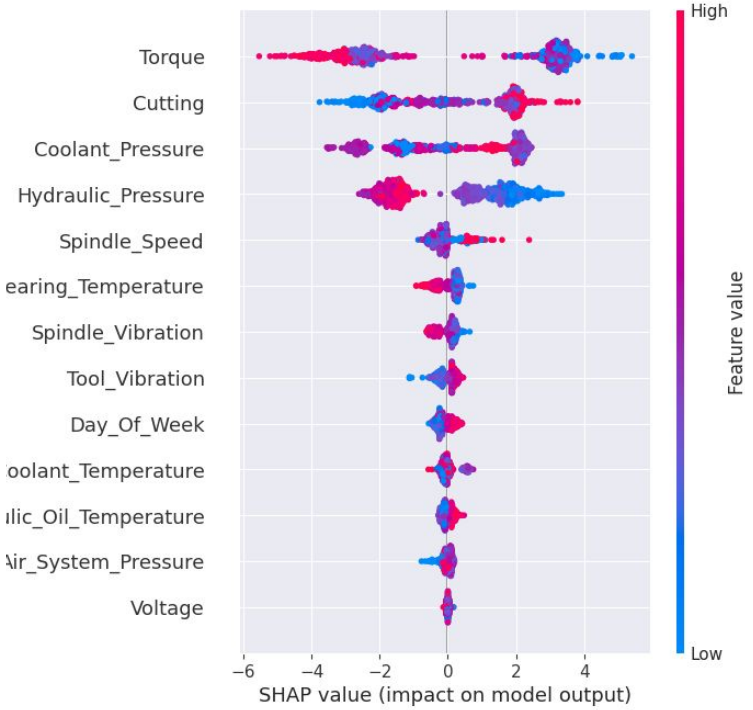

IMPORTÂNCIA ESTRUTURAL (XGBOOST)

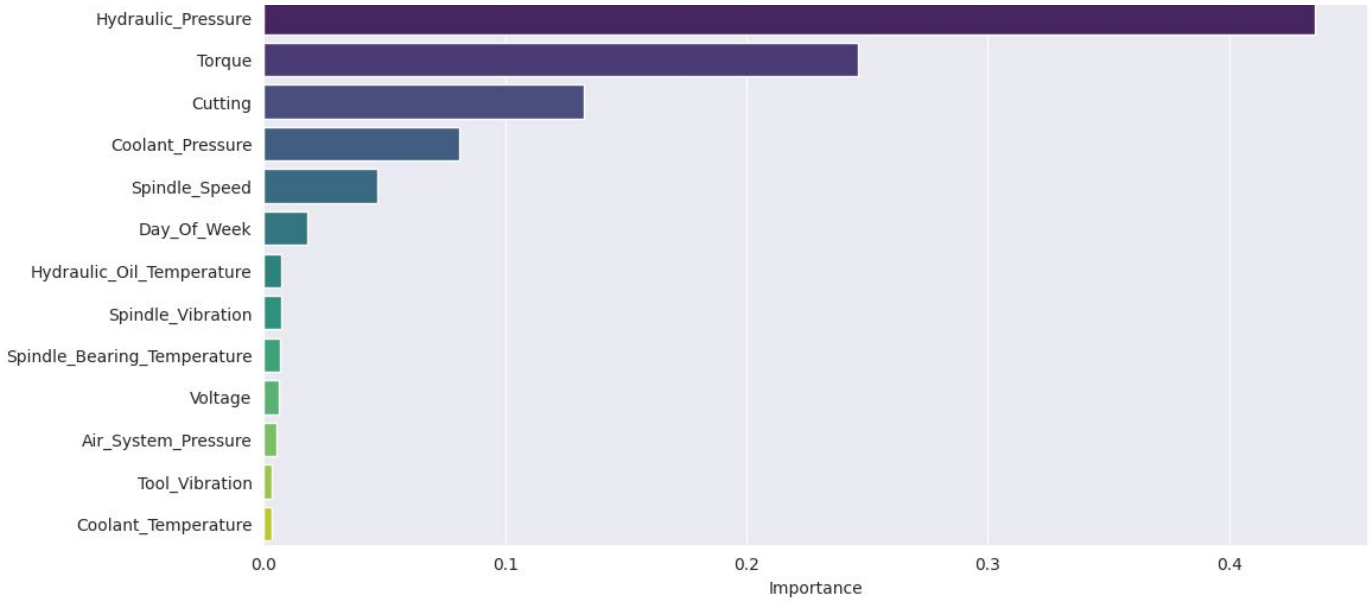

XGBoost

Análise SHAP de uma Ocorrência de Downtime

A explicação SHAP para essa observação mostra que as variáveis mais influentes empurraram fortemente o modelo a prever downtime com altíssima confiança — 99,97% de probabilidade.

EXPLICAÇÃO SHAP PARA A OBSERVAÇÃO DO CONJ. DE TESTE

	Hydraulic_Pressure	Coolant_Pressure	Air_System_Pressure	Coolant_Temperature	Hydraulic_Oil_Temperature	Spindle_Bearing_Temperature	Spindle_Vibration	Tool_Vibration	Spindle_Speed	Voltage	Torque	Cutting	Day_Of_Week	Downtime
694	77.59	4.258446	5.692249	18.5	49.7	37.6	1.106	17.026	17076.0	417.0	27.957484	3.67	1.0	1.0

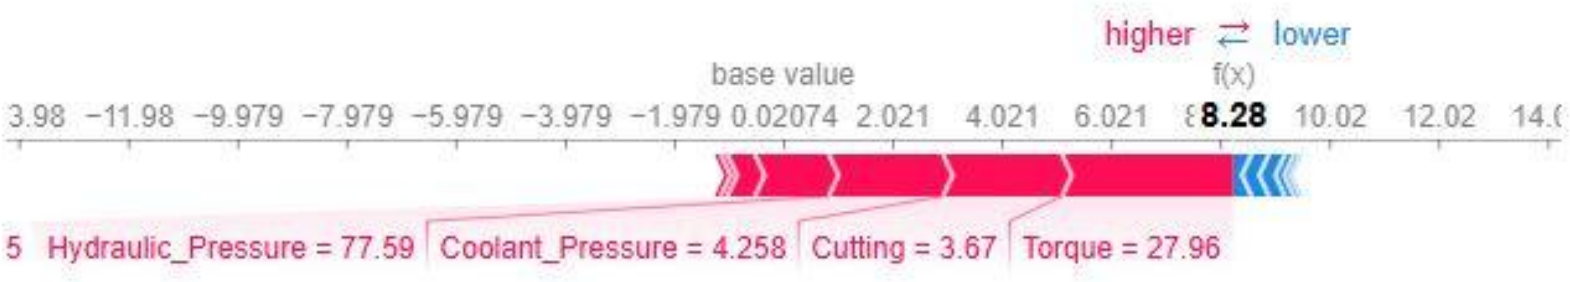

PREDIÇÃO CORRETA

99,97% de probabilidade: quase certeza de falha

As variáveis destacadas em vermelho aumentaram significativamente a probabilidade de downtime nessa instância.

Resultados preliminares & Conclusão

O dataset forneceu uma base sólida para **prever ocorrências de downtime**, permitindo a identificação de padrões relevantes e das variáveis mais influentes nas falhas das máquinas.

Desempenho do Modelo **XGBoost**

99.99%	PERFORMANCE	Alto F1-score na classificação de ocorrências de downtime.
3 a 4	VARIÁVEIS-CHAVE	Identificação de variáveis-chave associadas às falhas.
SHAP	INTERPRETABILIDADE	interpretação clara da importância das variáveis, auxiliando no diagnóstico de falhas.

Simulação Financeira

CONJ. TESTE: ~84 falhas mensais (alta frequência de falhas)

MATRIZ DE CONFUSÃO: TN: 368, FP: 0, FN: 1, TP: 381

Com base na lógica financeira da simulação, a manutenção preditiva é **economicamente atrativa**, o que se verifica na maioria dos cenários sob as premissas estabelecidas.

PARÂMETROS DA SIMULAÇÃO

Impacto receita p/hora de inatividade (USD)	$1,000
Custo mensal do sistema de ML (USD)	$1,000
Duração manutenção downtime (horas)	1 hour
Duração manutenção preditiva (horas)	1 hour
Custo/hora da manutenção reativa (USD)	$100
Custo/hora da manutenção preditiva (USD)	$50

RESULTADOS DA SIMULAÇÃO

Reativa: Custo mensal	$92,691 ($1,100 por evento)
Preditiva: Custo mensal	$89,489 ($1,050 por evento)
Benefício mensal líquido	$3,202
ROI (vs Custo do Modelo)	320.22%

A magnitude do ROI deve ser interpretada como um cenário otimista, impulsionado por alta frequência de falhas, desempenho preditivo extremamente forte e por premissas de custo simplificadas.

Simulação Financeira

Widget Interativo
disponível no binder

launch binder

Simulador Interativo ¶

Ajuste os parâmetros abaixo para comparar os custos entre **manutenção reativa e manutenção preditiva**.

Impacto na Receita por Hora	1000
Custo Mensal do Sistema de ML	1000
Duração do Downtime (horas)	1.00
Duração da Manutenção Preditiva	1.00
Custo Operacional do Downtime / hora	100
Custo Operacional da Manutenção Preditiva / hora	50

Eventos Mensais Normalizados

	Métrica	Valor
0	Falhas (Cenário Reativo)	84.26
1	Intervenções Preditivas	84.04
2	Falhas Não Detectadas	0.22

Comparação Financeira

	Métrica	Valor
0	Custo Mensal (Manutenção Reativa)	$92,691
1	Custo Mensal (Manutenção Preditiva)	$89,489
2	Benefício Financeiro Mensal	$3,202
3	ROI	320.22%

✅ Economicamente Viável

A magnitude do ROI deve ser interpretada como um cenário otimista, impulsionado por alta frequência de falhas, desempenho preditivo extremamente forte e por premissas de custo simplificadas.

Próximos Passos & objetivos

MELHORIA NA QUALIDADE DOS DADOS

É necessário aprofundar a investigação sobre as inconsistências nas medições. É recomendado melhorar a dimensão temporal e aplicar engenharia de variáveis temporais para capturar degradação gradual.

COMPLEMENTAR COM DETECÇÃO DE ANOMALIAS

Explorar modelos em tempo real (como Isolation Forest ou LSTM) para identificar padrões inesperados e reforçar a robustez da previsão.

IMPLEMENTAR PIPELINE DE MANUTENÇÃO PREDITIVA

Integrar o modelo em um sistema em tempo real com ferramentas como Kafka, Grafana ou dashboards IoT, permitindo alertas proativos.

ESTABELECER ESTRATÉGIA DE MONITORAMENTO CONTÍNUO

É essencial estabelecer uma estratégia de monitoramento contínuo após a implantação, começando com o acompanhamento da performance e coleta de feedback dos operadores.

Otimizar estratégias e cronogramas de manutenção por meio da manutenção preditiva pode gerar diversos benefícios práticos e estratégicos para a empresa. Aqui estão alguns dos principais resultados possíveis:

- ✓ **Aumento da Disponibilidade das Máquinas**
- ✓ **Redução de Custos Operacionais**
- ✓ **Melhoria no Planejamento da Produção**
- ✓ **Extensão da Vida Útil dos Equipamentos**
- ✓ **Ampliação da Produção e Ganhos em Escala**
- ✓ **Melhoria na Qualidade do Produto**

#Portólio Ciência de dados

Agradecimentos

Agradeço por acompanhar esta análise.

Este trabalho faz parte do meu portfólio em Ciência de Dados e está disponível na íntegra no meu perfil do **GitHub**, incluindo o código, visualizações e detalhes técnicos.

Para saber mais sobre meus projetos, convido você a visitar o meu perfil no **LinkedIn**.

Será um prazer conectar!

Autoria & desenvolvimento:

MonicaNeli

kaggle

Mônica Neli de Resende

LinkedIn